


ARQUITECTURA



ORGANIZACIÓN



spark-jobs

(Entrenar modelo y hacer predicción)



web

(Flask: blueprints)



docker

(dockerfiles)



dags

(DAG de entrenar modelo)



scripts

(Funciones auxiliares)




start.py

(Levantar entorno)

DATA LAKEHOUSE

ICEBERG + MINIO






SPARK

ENTRENAMIENTO


1. Bucketizer



2. StringIndexer

Carrier		Carrier_Index
AA	→	0.0
DL	→	1.0
UA	→	2.0
AA	→	0.0

3. VectorAssembler





KAFKA

TOPICS

REQUEST

UUID
Origin
Dest
Carrier
FlightNum
FlightDate
DepDelay
Distance
DayOfYear/Month/Week
model_ids


RESPONSE


UUID
Origin
Dest
Carrier
FlightNum
FlightDate
DepDelay
Distance
DayOfYear/Month/Week
model_id
prediction



SPARK

PREDICCIÓN





CASSANDRA

ESTRUCTURA


Columna	Tipo	Descripción
origin	PK text	Código aeropuerto origen
dest	PK text	Código aeropuerto destino
distance	double	Millas entre ambos

Columna	Tipo	Descripción
uuid	PK text	Código aeropuerto origen (PK)
prediction	int	on_time, slightly_early, slightly_late, very_late
origin	text	Aeropuerto origen
dest	text	Aeropuerto destino
dep_delay	double	Retraso de salida (minutos)
carrier	text	Código aerolínea
flight_date	text	Fecha del vuelo
flight_num	text	Número de vuelo
distance	double	Distancia en millas
...	...	...
timestamp	text	Cuándo se hizo la predicción



AIRFLOW

CREAR MODELO



MLFLOW

GUARDAR MODELO

